

# Derivación del problema de optimización de PCA

Percepción - ETSInf

Curso 2018/2019

## Equivalencia del error de reconstrucción

La reconstrucción de la muestra de entrenamiento  $\hat{\mathbf{x}}_i$  se formula como:

$$\hat{\mathbf{x}}_i = \bar{\mathbf{x}} + WW^t(\mathbf{x}_i - \bar{\mathbf{x}}) \quad (1)$$

donde  $W \in \mathbb{R}^{D \times k}$  es la matriz proyección a  $k$  dimensiones,  $(\mathbf{x}_i - \bar{\mathbf{x}}) \in \mathbb{R}^{D \times 1}$ , y  $\hat{\mathbf{x}}_i \in \mathbb{R}^{D \times 1}$ . Teniendo en cuenta que  $W = (\mathbf{w}_1 \mathbf{w}_2 \dots \mathbf{w}_k)$  es ortonormal ( $\mathbf{w}_i \cdot \mathbf{w}_j = 0$  si  $i \neq j$  y  $\mathbf{w}_j \mathbf{w}_j = 1$ ), tendremos:

$$W \cdot W^t(\mathbf{x}_i - \bar{\mathbf{x}}) = \sum_{j=1}^k \mathbf{w}_j^t (\mathbf{x}_i - \bar{\mathbf{x}}) \mathbf{w}_j$$

siendo  $\mathbf{w}_j \in \mathbb{R}^{D \times 1}$  y  $(\mathbf{x}_i - \bar{\mathbf{x}}) \in \mathbb{R}^{D \times 1}$ , el resultado de ese primer producto es un escalar resultado de proyectar  $(\mathbf{x}_i - \bar{\mathbf{x}})$  por  $\mathbf{w}_j^t$ . Al escalar resultante le llamaremos  $z_j^i$ , y es el valor de la dimensión  $j \in \{1, \dots, k\}$  de la proyección de  $\mathbf{x}_i$ . Por tanto, reescribimos Ec. 1 como

$$\hat{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{j=1}^k z_j^i \mathbf{w}_j$$

donde se suma el producto de  $z_j^i$  por  $\mathbf{w}_j$  para todo  $j \in \{1, \dots, k\}$ , y finalmente se suma  $\bar{\mathbf{x}}$ .

Al ser  $W$  ortonormal, cualquier  $\mathbf{x}_i$  puede ser reconstruido *sin error* con  $D$  vectores  $\mathbf{w}_j$ . Es decir, tomando  $k = D$  tendremos que  $W \in \mathbb{R}^{D \times D}$  y por tanto

$$\mathbf{x}_i = \hat{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{j=1}^D z_j^i \mathbf{w}_j^t$$

Es decir, los vectores reconstruidos son los originales<sup>1</sup>. Esto se puede conseguir, por ejemplo, con  $W = I$  (matriz identidad).

---

<sup>1</sup>Realmente lo que se obtiene son los vectores originales expresados en los ejes de coordenadas definidos por la matriz de proyección  $W$  completa.

El error de reconstrucción para  $k < D$  dimensiones puede calcularse como

$$\text{error}_k = \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2$$

Teniendo en cuenta que  $\mathbf{x}_i = \bar{\mathbf{x}} + \sum_{j=1}^D z_j^i \mathbf{w}_j$  y  $\hat{\mathbf{x}}_i = \bar{\mathbf{x}} + \sum_{j=1}^k z_j^i \mathbf{w}_j$

$$\begin{aligned} \text{error}_k &= \sum_{i=1}^n \|\mathbf{x}_i - \hat{\mathbf{x}}_i\|^2 \\ &= \sum_{i=1}^n \left\| \left( \bar{\mathbf{x}} + \sum_{j=1}^D z_j^i \mathbf{w}_j \right) - \left( \bar{\mathbf{x}} + \sum_{j=1}^k z_j^i \mathbf{w}_j \right) \right\|^2 \\ &= \sum_{i=1}^n \left\| \sum_{j=k+1}^D z_j^i \mathbf{w}_j \right\|^2 \\ &= \sum_{i=1}^n \left( \sum_{j=k+1}^D z_j^i \mathbf{w}_j \right)^t \left( \sum_{j=k+1}^D z_j^i \mathbf{w}_j \right) \\ &= \sum_{i=1}^n \left( \sum_{j=k+1}^D z_j^i \mathbf{w}_j^t \right) \left( \sum_{j=k+1}^D z_j^i \mathbf{w}_j \right) \end{aligned}$$

Desarrollando el sumatorio

$$\text{error}_k = \sum_{i=1}^n (z_{k+1}^i \mathbf{w}_{k+1}^t + \dots + z_D^i \mathbf{w}_D^t) (z_{k+1}^i \mathbf{w}_{k+1} + \dots + z_D^i \mathbf{w}_D)$$

Aplicando la propiedad distributiva y usando la ortonormalidad tendremos:

$$\begin{aligned} \text{error}_k &= \sum_{i=1}^n (z_{k+1}^i \mathbf{w}_{k+1}^t) (z_{k+1}^i \mathbf{w}_{k+1} + z_{k+2}^i \mathbf{w}_{k+2} + \dots + z_D^i \mathbf{w}_D) + \\ &\quad (z_{k+2}^i \mathbf{w}_{k+2}^t) (z_{k+1}^i \mathbf{w}_{k+1} + z_{k+2}^i \mathbf{w}_{k+2} + \dots + z_D^i \mathbf{w}_D) + \dots + \\ &\quad (z_D^i \mathbf{w}_D^t) (z_{k+1}^i \mathbf{w}_{k+1} + z_{k+2}^i \mathbf{w}_{k+2} + \dots + z_D^i \mathbf{w}_D) \end{aligned}$$

$$\begin{aligned}
&= \sum_{i=1}^n \left( z_{k+1}^i \right)^2 \mathbf{w}_{k+1}^t \mathbf{w}_{k+1} + z_{k+1}^i z_{k+2}^i \mathbf{w}_{k+1}^t \mathbf{w}_{k+2} + \dots + z_{k+1}^i z_D^i \mathbf{w}_{k+1}^t \mathbf{w}_D + \\
&\quad z_{k+2}^i z_{k+1}^i \mathbf{w}_{k+2}^t \mathbf{w}_{k+1} + \left( z_{k+2}^i \right)^2 \mathbf{w}_{k+2}^t \mathbf{w}_{k+2} + \dots + z_{k+2}^i z_D^i \mathbf{w}_{k+2}^t \mathbf{w}_D + \dots + \\
&\quad z_D^i z_{k+1}^i \mathbf{w}_D^t \mathbf{w}_{k+1} + z_D^i z_{k+2}^i \mathbf{w}_D^t \mathbf{w}_{k+2} + \dots + \left( z_D^i \right)^2 \mathbf{w}_D^t \mathbf{w}_D \\
&= \sum_{i=1}^n \left( z_{k+1}^i \right)^2 + \left( z_{k+2}^i \right)^2 + \dots + \left( z_D^i \right)^2 = \sum_{i=1}^n \sum_{j=k+1}^D \left( z_j^i \right)^2
\end{aligned}$$

Retomando el valor de  $z_j^i = \mathbf{w}_j^t (\mathbf{x}_i - \bar{\mathbf{x}})$

$$\begin{aligned}
\text{error}_k &= \sum_{i=1}^n \sum_{j=k+1}^D \left( z_j^i \right)^2 = \sum_{i=1}^n \sum_{j=k+1}^D \left( \mathbf{w}_j^t (\mathbf{x}_i - \bar{\mathbf{x}}) \right)^2 \\
&= \sum_{i=1}^n \sum_{j=k+1}^D \mathbf{w}_j^t (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^t \mathbf{w}_j
\end{aligned}$$

Intercambiando sumatorios

$$\text{error}_k = \sum_{j=k+1}^D \sum_{i=1}^n \mathbf{w}_j^t (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^t \mathbf{w}_j$$

Como las  $\mathbf{w}_j$  son independientes de  $i$  se pueden sacar del sumatorio interno, con lo cual

$$\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \left( \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^t \right) \mathbf{w}_j$$

Dado que la matriz de covarianzas de los datos  $\Sigma_{\mathcal{X}} = \frac{1}{n} \sum_{i=1}^n (\mathbf{x}_i - \bar{\mathbf{x}}) (\mathbf{x}_i - \bar{\mathbf{x}})^t$ , queda finalmente que

$$\text{error}_k = n \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

Para la derivación del error, se optimiza respecto a la matriz de proyección  $W$ . Por tanto, no hay dependencia del número de datos  $n$ , por lo que generalmente usaremos:

$$\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

## Derivada del error de reconstrucción

Nuestra función objetivo a minimizar es el error de reconstrucción  $\text{error}_k = \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$  mediante la matriz de proyección  $W$  a  $k$  dimensiones. Así, el problema de optimización se formula como

$$\widehat{W} = \underset{W \in \mathbb{R}^{D \times k}}{\operatorname{argmin}} \sum_{j=k+1}^D \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j = \underset{W \in \mathbb{R}^{D \times k}}{\operatorname{argmax}} \sum_{j=1}^k \mathbf{w}_j^t \Sigma_{\mathcal{X}} \mathbf{w}_j$$

Simplificando el problema anterior al caso de la proyección del conjunto de entrenamiento a una única dimensión dado por  $\mathbf{w}$ , esto se puede formular como

$$\hat{\mathbf{w}} = \underset{\mathbf{w} \in \mathbb{R}^D}{\operatorname{argmax}} \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} \quad \text{sujeto a que} \quad \mathbf{w}^t \mathbf{w} = 1$$

Este es un problema de maximización con restricciones que puede formularse a través de los multiplicadores de Lagrange, de forma que queda como

$$\hat{\mathbf{w}} = \underset{\mathbf{w} \in \mathbb{R}^D}{\operatorname{argmax}} \max_{\lambda \in \mathbb{R}} \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})$$

Para la optimización se procede a derivar e igualar a cero. Para ello, primero debemos identificar el tipo de función  $E$  que vamos a derivar, que en este caso es

$$E = \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})$$

Por análisis de dimensiones se puede observar que ambos términos son escalares. Ahora se debe proceder a la derivación respecto a cada una de las variables de optimización: el vector de proyección  $\mathbf{w}$  y el multiplicador de Lagrange  $\lambda$ .

### Derivada respecto a $\lambda$

La derivada respecto al multiplicador de Lagrange  $\lambda$ , que es un escalar, es trivial. La derivada del primer término es cero y la derivada del segundo resulta en

$$\frac{\partial E}{\partial \lambda} = 1 - \mathbf{w}^t \mathbf{w} = 0 \rightarrow \mathbf{w}^t \mathbf{w} = 1$$

Simplemente nos recuerda que  $\mathbf{w}$  debe ser de módulo unitario

### Derivada respecto a $\mathbf{w}$

La derivada de la función escalar  $E$  respecto al vector  $\mathbf{w} = (w_1 \cdots w_D)^t$  es

$$\frac{\partial E}{\partial \mathbf{w}} = \left( \frac{\partial E}{\partial w_1}, \frac{\partial E}{\partial w_2}, \dots, \frac{\partial E}{\partial w_D} \right)$$

Resulta en un vector fila donde la componente  $j$  es la derivada de  $E$  respecto a  $w_j$ . Por simplicidad, hagamos la derivada respecto a  $w_1$  desarrollando  $E$

$$\frac{\partial E}{\partial w_1} = \frac{\partial \mathbf{w}^t \Sigma_{\mathcal{X}} \mathbf{w} + \lambda (1 - \mathbf{w}^t \mathbf{w})}{\partial w_1} = \frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_1} + \frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_1}$$

Haciendo primero la derivada del segundo sumando

$$\begin{aligned} \frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_1} &= \lambda \frac{\partial (1 - \sum_{i=1}^D w_i^2)}{\partial w_1} \\ &= \lambda \frac{\partial (1 - (w_1^2 + w_2^2 + \dots + w_D^2))}{\partial w_1} = \lambda (-2w_1) = -2\lambda w_1 \end{aligned}$$

En general, tendríamos  $\frac{\partial \lambda (1 - \sum_{i=1}^D w_i^2)}{\partial w_j} = -2\lambda w_j$ , con lo cual, si realizáramos la derivada del segundo término respecto al vector  $\mathbf{w}$  completo se obtiene

$$\frac{\partial \lambda (1 - (w_1^2 + w_2^2 + \dots + w_D^2))}{\partial \mathbf{w}} = (-2\lambda w_1, -2\lambda w_2, \dots, -2\lambda w_D) = -2\lambda \mathbf{w}^t$$

Respecto a la derivada del primer sumando

$$\begin{aligned} \frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_1} &= \\ &= \frac{\partial (\sum_{j=1}^D w_1 \Sigma_{1j} w_j + \sum_{j=1}^D w_2 \Sigma_{2j} w_j + \dots + \sum_{j=1}^D w_D \Sigma_{Dj} w_j)}{\partial w_1} \\ &= \frac{\partial (w_1 \Sigma_{11} w_1 + w_1 \Sigma_{12} w_2 + \dots + w_1 \Sigma_{1D} w_D)}{\partial w_1} + \\ &\quad \frac{\partial (w_2 \Sigma_{21} w_1 + w_2 \Sigma_{22} w_2 + \dots + w_2 \Sigma_{2D} w_D)}{\partial w_1} + \dots + \\ &\quad \frac{\partial (w_D \Sigma_{D1} w_1 + w_D \Sigma_{D2} w_2 + \dots + w_D \Sigma_{DD} w_D)}{\partial w_1} \\ &= (2w_1 \Sigma_{11} + \Sigma_{12} w_2 + \dots + \Sigma_{1D} w_D) + w_2 \Sigma_{21} + \dots + w_D \Sigma_{D1} \\ &= (\Sigma_{11} w_1 + \Sigma_{12} w_2 + \dots + \Sigma_{1D} w_D) + (w_1 \Sigma_{11} + w_2 \Sigma_{21} + \dots + w_D \Sigma_{D1}) \\ &= \sum_{j=1}^D \Sigma_{1j} w_j + \sum_{i=1}^D w_i \Sigma_{i1} \end{aligned}$$

Teniendo en cuenta que  $\Sigma_{\mathcal{X}}$  es simétrica y, por tanto,  $\Sigma_{ij} = \Sigma_{ji}$ , queda como

$$2 \sum_{i=1}^D w_i \Sigma_{i1} = 2 \mathbf{w}^t \Sigma_{\bullet 1}$$

Donde  $\Sigma_{\bullet i}$  indica la  $i$ -ésima columna de  $\Sigma_{\mathcal{X}}$ . Por tanto, en general para cualquier  $w_k$  tendríamos que

$$\frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial w_k} = 2\mathbf{w}^t \Sigma_{\bullet k}$$

Por tanto, si realizáramos la derivada del primer término respecto al vector  $\mathbf{w}$  completo tendríamos

$$\frac{\partial \sum_{i=1}^D \sum_{j=1}^D w_i \Sigma_{ij} w_j}{\partial \mathbf{w}} = (2\mathbf{w}^t \Sigma_{\bullet 1}, 2\mathbf{w}^t \Sigma_{\bullet 2}, \dots, 2\mathbf{w}^t \Sigma_{\bullet D}) = 2\mathbf{w}^t \Sigma_{\mathcal{X}}$$

En consecuencia, la derivada de  $E$  respecto a  $\mathbf{w}$  queda como

$$\frac{\partial E}{\partial \mathbf{w}} = 2\mathbf{w}^t \Sigma_{\mathcal{X}} - 2\lambda \mathbf{w}^t$$

Al igualar a cero

$$2\mathbf{w}^t \Sigma_{\mathcal{X}} - 2\lambda \mathbf{w}^t = 0 \rightarrow 2\mathbf{w}^t \Sigma_{\mathcal{X}} = 2\lambda \mathbf{w}^t \rightarrow \mathbf{w}^t \Sigma_{\mathcal{X}} = \lambda \mathbf{w}^t \rightarrow \Sigma_{\mathcal{X}} \mathbf{w} = \lambda \mathbf{w}$$

Es decir,  $\mathbf{w}$  es un vector propio con  $\lambda$  valor propio asociado.